TOULOUSE LAUTREC

APRENDIZAJE AUTOMATICO CON PYTHON

METODOS DE REGRESION



Ing. Alexander Valdez Curso 2290, Clases Lunes y Miercoles 20:00-22:30pm Segunda Clase

Boston Dataset

- Contains information about different houses in Boston.
- There are 506 samples and 13 feature variables in this dataset.
- Maintained at Carnegie Mellon University.
- This is a copy of UCI ML housing dataset.

We want to predict the value of prices of the house using the given features.

```
In [ ]: import pandas as pd
boston_data = pd.read_csv("https://raw.githubusercontent.com/sebastianVP/ML_PROJECT/mast
boston_data.head()
```

Out[]:		crim	zn	indus	chas	nox	rm	age	dis	rad	tax	ptratio	b	Istat	medv
	0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296	15.3	396.90	4.98	24.0
	1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242	17.8	396.90	9.14	21.6
	2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242	17.8	392.83	4.03	34.7
	3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222	18.7	394.63	2.94	33.4
	4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222	18.7	396.90	5.33	36.2

```
4.980e+00])
In []: bos_pd = pd.DataFrame(boston_data.values[:,:-1])
bos_pd.head()
```

_		0	1	2	3	4	5	6	7	8	9	10	11	12
	0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98
	1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14
	2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03
	3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94
	4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3.0	222.0	18.7	396.90	5.33

Attribute Information:

2 0.02729

3 0.03237

4 0.06905

0.0

0.0

0.0

7.07

2.18

2.18

0.0 0.469 7.185

0.0 0.458 6.998

0.0 0.458 7.147

Out[]:

Acronym	Description
CRIM	Per capita crime rate by town
ZN	Proportion of residential land zoned for lots over 25,000 sq.ft.
INDUS	Proportion of non-retail business acres per town
CHAS	Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)
NOX	Nitric oxides concentration (parts per 10 million)
RM	Average number of rooms per dwelling
AGE	roportion of owner-occupied units built prior to 1940
DIS	weighted distances to five Boston employment centres
RAD	index of accessibility to radial highways
TAX	full-value property-tax rate per \$10,000
PTRATIO	pupil-teacher ratio by town
В	1000(Bk - 0.63)^2 where Bk is the proportion of blacks by town
LSTAT	% lower status of the population
MEDV	Median value of owner-occupied homes in \$1000's

```
In [ ]: print("Keys: ", boston_data.keys())
        Keys: Index(['crim', 'zn', 'indus', 'chas', 'nox', 'rm', 'age', 'dis', 'rad', 'tax',
                'ptratio', 'b', 'lstat', 'medv'],
              dtype='object')
        bos_pd.columns = ['CRIM','ZN','INDUS','CHAS','NOX','RM','AGE','DIS','RAD','TAX','PTRATIO
In [ ]:
        bos pd.head()
                   ZN INDUS CHAS NOX
                                                      DIS RAD
                                                                TAX PTRATIO
                                                                                  B LSTAT
Out[]:
            CRIM
                                           RM AGE
        0 0.00632 18.0
                         2.31
                                0.0 0.538 6.575
                                               65.2 4.0900
                                                            1.0 296.0
                                                                         15.3 396.90
                                                                                      4.98
        1 0.02731
                         7.07
                                0.0 0.469 6.421
                                               78.9 4.9671
                                                            2.0 242.0
                                                                         17.8 396.90
                                                                                      9.14
                   0.0
```

61.1 4.9671

45.8 6.0622

54.2 6.0622

2.0 242.0

3.0 222.0

3.0 222.0

17.8 392.83

18.7 394.63

18.7 396.90

4.03

2.94

5.33

```
bos pd['PRICE']=boston data.values[:,-1]
In [ ]:
         bos pd.head()
                                        NOX
                                                            DIS RAD
                                                                       TAX PTRATIO
              CRIM
                     ZN INDUS CHAS
                                               RM AGE
                                                                                          B LSTAT PRICE
Out[]:
         0.00632
                    18.0
                                                                      296.0
                            2.31
                                   0.0 0.538 6.575
                                                    65.2 4.0900
                                                                  1.0
                                                                                 15.3 396.90
                                                                                               4.98
                                                                                                      24.0
         1 0.02731
                            7.07
                                   0.0 0.469
                                             6.421
                                                    78.9 4.9671
                                                                  2.0
                                                                      242.0
                                                                                 17.8 396.90
                                                                                               9.14
                                                                                                     21.6
         2 0.02729
                     0.0
                            7.07
                                                                                 17.8 392.83
                                                                                                      34.7
                                   0.0
                                       0.469 7.185
                                                    61.1 4.9671
                                                                  2.0
                                                                      242.0
                                                                                               4.03
```

45.8 6.0622

54.2 6.0622

3.0 222.0

3.0 222.0

18.7 394.63

18.7 396.90

2.94

5.33

33.4

36.2

Pass the data into a Pandas dataframe

2.18

2.18

0.0

0.0

Exploratory Data Analysis

- Important step before training the model.
- We use statistical analysis and visualizations to understand the relationship of the target variable with other features.

Check Missing Values

3 0.03237

0.06905

It is a good practice to see if there are any missing values in the data.

0.458

0.0 0.458 7.147

6.998

Count the number of missing values for each feature

```
bos pd.isnull().sum()
         CRIM
Out[]:
         ZN
                     0
         INDUS
                     0
                     0
         CHAS
         NOX
                     0
         RM
                     0
         AGE
                     0
         DIS
                     0
         RAD
                     0
                     0
         TAX
         PTRATIO
                     0
         LSTAT
                     0
         PRICE
         dtype: int64
```

Obtain basic statistics on the data

n []:	bos	_pd													
ut[]:		CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	В	LSTAT	PRICE
	0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98	24.0
	1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14	21.6
	2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03	34.7

3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3.0	222.0	18.7	396.90	5.33	36.2
•••														
501	0.06263	0.0	11.93	0.0	0.573	6.593	69.1	2.4786	1.0	273.0	21.0	391.99	9.67	22.4
502	0.04527	0.0	11.93	0.0	0.573	6.120	76.7	2.2875	1.0	273.0	21.0	396.90	9.08	20.6
503	0.06076	0.0	11.93	0.0	0.573	6.976	91.0	2.1675	1.0	273.0	21.0	396.90	5.64	23.9
504	0.10959	0.0	11.93	0.0	0.573	6.794	89.3	2.3889	1.0	273.0	21.0	393.45	6.48	22.0
505	0.04741	0.0	11.93	0.0	0.573	6.030	80.8	2.5050	1.0	273.0	21.0	396.90	7.88	11.9

506 rows × 14 columns

```
In [ ]: bos_pd.describe().transpose()
```


\cap		4	Г	- 7	
U	u	L			

	count	mean	std	min	25%	50%	75%	max
CRIM	506.0	3.613524	8.601545	0.00632	0.082045	0.25651	3.677083	88.9762
ZN	506.0	11.363636	23.322453	0.00000	0.000000	0.00000	12.500000	100.0000
INDUS	506.0	11.136779	6.860353	0.46000	5.190000	9.69000	18.100000	27.7400
CHAS	506.0	0.069170	0.253994	0.00000	0.000000	0.00000	0.000000	1.0000
NOX	506.0	0.554695	0.115878	0.38500	0.449000	0.53800	0.624000	0.8710
RM	506.0	6.284634	0.702617	3.56100	5.885500	6.20850	6.623500	8.7800
AGE	506.0	68.574901	28.148861	2.90000	45.025000	77.50000	94.075000	100.0000
DIS	506.0	3.795043	2.105710	1.12960	2.100175	3.20745	5.188425	12.1265
RAD	506.0	9.549407	8.707259	1.00000	4.000000	5.00000	24.000000	24.0000
TAX	506.0	408.237154	168.537116	187.00000	279.000000	330.00000	666.000000	711.0000
PTRATIO	506.0	18.455534	2.164946	12.60000	17.400000	19.05000	20.200000	22.0000
В	506.0	356.674032	91.294864	0.32000	375.377500	391.44000	396.225000	396.9000
LSTAT	506.0	12.653063	7.141062	1.73000	6.950000	11.36000	16.955000	37.9700
PRICE	506.0	22.532806	9.197104	5.00000	17.025000	21.20000	25.000000	50.0000

Distribution of the target variable

```
In []: import matplotlib.pyplot as plt
   plt.figure(figsize=(8, 6));
   plt.hist(bos_pd['PRICE']);
   plt.title('Boston Housing Prices and Count Histogram');
   plt.xlabel('price ($1000s)');
   plt.ylabel('count');
   plt.show();
```





```
In []: import seaborn as sns


plt.figure(figsize=(8, 6));
    sns.distplot(bos_pd['PRICE']);

<ipython-input-14-b7b47e3d823d>:4: UserWarning:
    `distplot` is a deprecated function and will be removed in seaborn v0.14.0.

Please adapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).

For a guide to updating your code to use the new functions, please see https://gist.github.com/mwaskom/de44147ed2974457ad6372750bbe5751

sns.distplot(bos_pd['PRICE']);
```




From the above output we can see that the values of PRICE is normally distributed with some of the outliers.

Heatmap: Two-Dimensional Graphical Representation

- Represent the individual values that are contained in a matrix as colors.
- Create a correlation matrix that measures the linear relationships between the variables.


```
In []: plt.figure(figsize=(12, 9));
    correlation_matrix = bos_pd.corr().round(2);
    sns.heatmap(correlation_matrix, cmap="YlGnBu", annot=True);
```





- **RM** tiene una fuerte correlación positiva con **PRICE** (0,7), mientras que **LSTAT tiene** una alta correlación negativa con **PRICE** (-0,74).
- Las características **RAD**, **TAX** tienen una correlación de 0,91. Estos pares de características están fuertemente correlacionados entre sí. Esto puede afectar el modelo. Lo mismo ocurre con las características **DIS** y **AGE** que tienen una correlación de -0,75.
- Las variables predictoras como **CRIM**, **INDUS**, **NOX**, **AGE**, **RAD**, **TAX**, **PTRATIO**, **LSTAT** tiene una correlación negativa con el objetivo. El aumento de cualquiera de ellos conlleva la bajada del precio de la vivienda.
- Las variables predictivas como **ZN**, **RM**, **DIS**, **B** tienen una buena correlación positiva con el objetivo. El aumento de cualquiera de ellos conlleva el aumento del precio de la vivienda.


```
In []: #for feature_name in housing.feature_names:
    for feature_name in bos_pd.columns:


        plt.figure(figsize=(5, 4));
        plt.scatter(bos_pd[feature_name], bos_pd['PRICE']);
        plt.ylabel('Price', size=12);
        plt.xlabel(feature_name, size=12);
        plt.show();
```


















- Los precios aumentan a medida que el valor de RM aumenta linealmente. Hay pocos valores atípicos y los datos parecen tener un límite de 50.
- Los precios tienden a bajar con un aumento de LSTAT. Aunque no parece seguir exactamente una línea lineal.



Model Selection Process




Image Source: Christophe Bourguignat

Es necesario entrenar un algoritmo de aprendizaje automático con un conjunto de datos para aprender las relaciones entre diferentes características y cómo estas características afectan la variable objetivo.

- Necesitamos dividir todo el conjunto de datos en dos conjuntos:
 - Conjunto de entrenamiento sobre el que vamos a entrenar nuestro algoritmo para construir un modelo.
 - Conjunto de pruebas en el que probaremos nuestro modelo para ver qué tan precisas son sus predicciones.

Antes de crear los dos conjuntos, necesitamos identificar el algoritmo que usaremos para nuestro modelo. Podemos usar el mapa como una hoja de trucos para seleccionar los algoritmos que podemos probar para construir nuestro modelo de predicción. Usando la lista de verificación, veamos en qué categoría se encuentra nuestro conjunto de datos actual:

- Disponemos de 506 muestras: >50? (Sí)
- ¿Estamos prediciendo una categoría? (**No**)
- ¿Estamos prediciendo una cantidad? (Sí)

Con base en la lista de verificación que preparamos anteriormente y siguiendo el machine_learning_map , podemos probar **métodos de regresión** como:

- Linear Regression
- Lasso
- ElasticNet Regression

- Ridge Regression:
- K Neighbors Regressor
- Decision Tree Regressor
- Simple Vector Regression (SVR)
- Ada Boost Regressor
- Gradient Boosting Regressor
- Random Forest Regression
- Extra Trees Regressor

Consulte los siguientes documentos sobre regresión: Supervised learning--scikit-learn, Learn regression algorithms using Python and scikit-learn, Non-Linear Regression Trees with scikit-learn.

Simple Linear Model

- Si es difícil visualizar las múltiples funciones.
- Queremos predecir el precio de la vivienda con una sola variable y luego pasar a la regresión con todas las características.
- Debido a que RM muestra una correlación positiva con los Precios de la vivienda, usaremos RM para el modelo.

Splitting the data into training and testing sets

(102, 1)

- Dividimos los datos en conjuntos de entrenamiento y prueba.
- Entrenamos el modelo con el 80% de las muestras y probamos con el 20% restante.
- Hacemos esto para evaluar el rendimiento del modelo en datos invisibles.

```
In []: from sklearn.model_selection import train_test_split

In []: X_train_1, X_test_1, Y_train_1, Y_test_1 = train_test_split(X_rooms, y_price, test_siz

    print(X_train_1.shape)
    print(Y_train_1.shape)
    print(X_test_1.shape)
    print(Y_test_1.shape)

    (404, 1)
    (404, 1)
    (102, 1)
```

Training and testing the model

- Usamos LinearRegression de scikit-learn para entrenar nuestro modelo tanto en el entrenamiento como en los conjuntos de prueba.
- Comprobamos el rendimiento del modelo en el conjunto de datos del tren.

Model Evaluation for Test Set


The coefficient of determination: 1 is perfect prediction

```
In [ ]: print(f'Coefficient of determination: {metrics.r2_score(Y_test_1, y_pred_1) :.4f}')
Coefficient of determination: 0.6938
```

45-Degree Plot

```
In []: plt.figure(figsize=(8, 5));
   plt.scatter(Y_test_1, y_pred_1);
   plt.plot([0, 50], [0, 50], '--k');
   plt.axis('tight');
   plt.xlabel("Actual House Prices ($1000)");
   plt.ylabel("Predicted House Prices: ($1000)");
   #plt.xticks(range(0, int(max(y_test)),2));
   #plt.yticks(range(0, int(max(y_test)),2));
   plt.title("Actual Prices vs Predicted prices");
   plt.tight_layout();
```





Modelo de regresión lineal con todas las variables

• Queremos crear un modelo considerando todas las características del conjunto de datos.

Creacion del modelo

0.04741

11.93

0.0 0.573 6.030

```
X = bos pd.drop('PRICE', axis = 1)
           y = bos pd['PRICE']
In [
                  CRIM
                               INDUS CHAS
                                               NOX
                                                             AGE
                                                                           RAD
                                                                                   TAX PTRATIO
                                                                                                        B LSTAT
Out[]:
                          ΖN
                                                       RM
                                                                      DIS
             0.00632
                         18.0
                                  2.31
                                                      6.575
                                                             65.2 4.0900
                                                                                  296.0
                                                                                                   396.90
                                                                                                             4.98
                                               0.538
                                                                             1.0
                                                                                             15.3
                                          0.0
                0.02731
                          0.0
                                  7.07
                                                             78.9 4.9671
                                                                             2.0
                                                                                 242.0
                                                                                                   396.90
                                                                                                             9.14
                                               0.469
                                                      6.421
                                                                                             17.8
                0.02729
                          0.0
                                  7.07
                                                     7.185
                                                             61.1 4.9671
                                                                             2.0
                                                                                 242.0
                                                                                                   392.83
                                                                                                             4.03
                                              0.469
                                                                                             17.8
                0.03237
                          0.0
                                  2.18
                                                      6.998
                                                             45.8
                                                                   6.0622
                                                                             3.0
                                                                                 222.0
                                                                                                   394.63
                                                                                                             2.94
                                               0.458
                                                                                             18.7
                0.06905
                                                                             3.0
                          0.0
                                  2.18
                                              0.458
                                                     7.147
                                                             54.2
                                                                   6.0622
                                                                                 222.0
                                                                                             18.7
                                                                                                   396.90
                                                                                                             5.33
                0.06263
                                 11.93
                                                             69.1 2.4786
                                                                                 273.0
                                                                                                   391.99
          501
                          0.0
                                          0.0 0.573 6.593
                                                                             1.0
                                                                                             21.0
                                                                                                             9.67
          502
                0.04527
                          0.0
                                 11.93
                                              0.573 6.120
                                                             76.7 2.2875
                                                                             1.0
                                                                                 273.0
                                                                                             21.0
                                                                                                   396.90
                                                                                                             9.08
                0.06076
                          0.0
                                 11.93
                                              0.573 6.976
                                                             91.0 2.1675
                                                                                 273.0
                                                                                                   396.90
                                                                                                             5.64
          503
                                                                             1.0
                                                                                             21.0
                0.10959
                          0.0
                                 11.93
                                              0.573 6.794
                                                             89.3
                                                                   2.3889
                                                                                273.0
                                                                                                   393.45
                                                                                                             6.48
                                                                             1.0
                                                                                             21.0
```

80.8 2.5050

1.0 273.0

21.0 396.90

7.88

```
In [ ]:
               24.0
Out[]:
              21.6
              34.7
        3
              33.4
              36.2
               . . .
        501
              22.4
        502
             20.6
        503 23.9
             22.0
        504
        505
              11.9
        Name: PRICE, Length: 506, dtype: float64
```

- Utilice train_test_split para dividir los datos en subconjuntos aleatorios de tren y prueba.
- Cada vez que lo ejecutes sin especificar random_state, obtendrás un resultado diferente.
- Si usa random_state=some_number , puede garantizar que la división será siempre la misma.
- No importa cuál sea el valor de random_state : 42, 0, 21, ...
- Esto es útil si desea resultados reproducibles.

```
In [ ]: X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,random_state=42)

El modelo de regresion lineal:

In [ ]: reg_all = LinearRegression()
    reg all.fit(X train, y train)
```

```
Out[]: V LinearRegression
LinearRegression()
```

Evaluación del modelo para el conjunto de entrenamiento


Evaluación del modelo para el conjunto de pruebas

```
print(f"The model performance for training set")
print(f"-----")
print(f"Root Mean Squared Error: {rmse}")
print(f"R^2: {r2}")
```

El coeficiente de determinación: 1 es predicción perfecta.

```
In [ ]: print(f'Coefficient of determination: {metrics.r2_score(y_test, y_pred) :.4f}')
Coefficient of determination: 0.6688
```

Error Distribution




45-Degree plot

```
In [ ]: plt.figure(figsize=(8, 5));
```


```
plt.scatter(y_test, y_pred);
plt.plot([0, 50], [0, 50], '--k');
plt.axis('tight');
plt.xlabel("Actual House Prices ($1000)");
plt.ylabel("Predicted House Prices: ($1000)");
#plt.xticks(range(0, int(max(y_test)),2));
#plt.yticks(range(0, int(max(y_test)),2));
plt.title("Actual Prices vs Predicted prices");
plt.tight_layout();
```

Actual Prices vs Predicted prices



	Actual	Predicted
173	23.6	28.996724
274	32.4	36.025565
491	13.6	14.816944
72	22.8	25.031979
452	16.1	18.769880
76	20.0	23.254429
316	17.8	17.662538
140	14.0	14.341190
471	19.6	23.013207
500	16.8	20.632456

Out[]



Eleccion del mejor modelo: k-Fold Cross-Validation

- La validación cruzada es un procedimiento de remuestreo que se utiliza para evaluar modelos de aprendizaje automático en una muestra de datos limitada.
- Se utiliza principalmente en el aprendizaje automático aplicado para estimar la habilidad de un modelo de aprendizaje automático en datos invisibles.
- Usamos una muestra limitada para estimar cómo se espera que funcione el modelo en general cuando se usa para hacer predicciones sobre datos no utilizados durante el entrenamiento del modelo.
- La mayor ventaja de este método es que cada punto de datos se utiliza para la validación exactamente una vez y para el entrenamiento k-1 veces.
- Para elegir el modelo final a utilizar, seleccionamos el que tiene el menor error de validación.\

El procedimiento general es el siguiente:

- 1. Mezcla el conjunto de datos aleatoriamente.
- 2. Dividir el conjunto de datos en k grupos
- 3. Para cada grupo único:\ 3.1 Tome el grupo como un conjunto de datos de prueba o de reserva\ 3.2 Tome los grupos k-1 restantes como un conjunto de datos de entrenamiento\ 3.3 Ajustar un modelo en el conjunto de entrenamiento y evaluarlo en el conjunto de prueba\ 3.4 Conservar la puntuación de la evaluación y descartar el modelo.
- 4. Resuma las habilidades del modelo utilizando la muestra de puntajes de evaluación del modelo.

¿Cómo elegir k?

• Un valor mal elegido para **k** puede dar lugar a una idea errónea de la habilidad del modelo, como una puntuación con una varianza alta o un sesgo alto.

- La elección de **k** suele ser 5 o 10, pero no existe una regla formal. A medida que **k** aumenta, la diferencia de tamaño entre el conjunto de entrenamiento y los subconjuntos de remuestreo se reduce. A medida que esta diferencia disminuye, el sesgo de la técnica se vuelve menor.
- Un valor de **k=10** es muy común en el campo del aprendizaje automático aplicado y se recomienda si tiene dificultades para elegir un valor para su conjunto de datos.

A continuación se muestra la visualización de una validación k veces cuando k = 5.




Image Source: https://scikit-learn.org/

```
In [ ]:
        np.sqrt(24.07)
        4.906118628814432
Out[]:
In [ ]:
        # import warnings filter
        from warnings import simplefilter
        # ignore all future warnings
        simplefilter(action='ignore', category=FutureWarning)
        from sklearn.model selection import KFold
        from sklearn.model selection import cross_val_score
        from sklearn.linear model import LinearRegression
        from sklearn.linear model import Lasso
        from sklearn.linear model import ElasticNet
        from sklearn.linear model import Ridge
        from sklearn.linear model import BayesianRidge
        from sklearn.tree import DecisionTreeRegressor
        from sklearn.neighbors import KNeighborsRegressor
        from sklearn.svm import SVR
        from sklearn.ensemble import AdaBoostRegressor
        from sklearn.ensemble import GradientBoostingRegressor
```


```
from sklearn.ensemble import RandomForestRegressor
# variables de usuario para ajustar
seed = 9
folds = 10
metric = "neg mean squared error"
# mantener diferentes modelos de regresión en un solo diccionario
models = dict()
models["Linear"] = LinearRegression()
models["Lasso"] = Lasso()
                      = Lasso()
models["Lasso"]
models["ElasticNet"] = ElasticNet()
models["Ridge"] = Ridge()
models["BayesianRidge"] = BayesianRidge()
models["KNN"] = KNeighborsRegressor()
models["DecisionTree"] = DecisionTreeRegressor()
models["SVR"] = SVR()
models["AdaBoost"] = AdaBoostRegressor()
models["GradientBoost"] = GradientBoostingRegressor()
models["RandomForest"] = RandomForestRegressor()
# Validación cruzada 10 veces para cada modelo
model results = list()
model names = list()
for model name in models:
    model = models[model name]
    k fold = KFold(n splits=folds, random state=seed, shuffle=True)
   results = cross val score (model, X train, y train, cv=k fold, scoring=metric)
   #print(results)
    model results.append(results)
    model names.append(model name)
    print("{:>20}: {:.2f}, {:.2f}".format(model name, round(results.mean(), 3),
                                  round(results.std(), 3)))
# box-whisker plot to compare regression models
import matplotlib.pyplot as plt
figure = plt.figure();
figure.suptitle('Regression models comparison');
ax = figure.add subplot(111);
plt.boxplot(model results);
ax.set xticklabels(model names, rotation = 45, ha="right");
ax.set ylabel("Mean Squared Error (MSE)");
plt.margins(0.05, 0.1);
#plt.savefig("model mse scores.png")
plt.show();
#plt.clf()
#plt.close()
              Linear: -24.07, 11.53
              Lasso: -28.88, 10.90
          ElasticNet: -28.89, 10.17
              Ridge: -24.23, 11.80
       BayesianRidge: -24.88, 11.69
                KNN: -44.99, 13.80
```

DecisionTree: -23.17, 9.98

AdaBoost: -16.15, 7.78 GradientBoost: -12.29, 4.78 RandomForest: -14.12, 8.09

SVR: -71.30, 31.05

Regression models comparison



Según la comparación anterior, podemos ver que el modelo "Regresión de aumento de gradiente" supera a todos los demás modelos de regresión.

Model with Gradient Boosted Tree

```
In [ ]: gbr = GradientBoostingRegressor()
    gbr.fit(X_train, y_train)

    gbr_predicted = gbr.predict(X_test)
    gbr_expected = y_test
```


Root Mean Square Error:

The coefficient of determination: (1 is perfect prediction)

Error Distribution


```
In [ ]: sns.distplot(gbr_expected - gbr_predicted);
```

```
<ipython-input-52-c11227365f33>:1: UserWarning:
    `distplot` is a deprecated function and will be removed in seaborn v0.14.0.
    Please adapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).
    For a guide to updating your code to use the new functions, please see https://gist.github.com/mwaskom/de44147ed2974457ad6372750bbe5751
    sns.distplot(gbr_expected - gbr_predicted);
```



45-Degree Plot

```
In []: plt.figure(figsize=(8, 5));
   plt.scatter(gbr_expected, gbr_predicted)
   plt.plot([0, 50], [0, 50], '--k');
   plt.axis('tight');
   plt.xlabel('True price ($1000s)');
   plt.ylabel('Predicted price ($1000s)');
   plt.tight_layout();
```




Zoom in:

```
In [ ]: df1 = pd.DataFrame({'Actual': gbr_expected, 'Predicted': gbr_predicted})
    df2 = df1.head(10)
    df2
```

```
Actual Predicted
Out[]:
          173
                 23.6
                      23.449761
         274
                 32.4 31.461360
         491
                 13.6 17.269762
           72
                 22.8 23.974831
         452
                 16.1 17.681144
           76
                 20.0 22.031128
         316
                 17.8 18.149588
         140
                 14.0 13.830452
         471
                     20.616193
          500
                 16.8 21.042857
```

```
In [ ]: df2.plot(kind='bar');
```



Fin del Cuaderno